

# Детальное представление результатов SVD-разложения по алгоритму 1

Никита Сорокин, КМБО-01-23

## 1 Введение

Сингулярное разложение (SVD) позволяет представить любую матрицу  $A$  в виде

$$A = U \Sigma V^T,$$

где:

- $U$  — матрица, столбцы которой являются ортонормированными левыми сингулярными векторами;
- $\Sigma$  — диагональная матрица, содержащая неотрицательные действительные сингулярные значения;
- $V^T$  — транспонированная (или, для комплексных данных, сопряжённо-транспонированная) матрица, столбцы которой — правые сингулярные векторы.

Этот метод используется для анализа структуры данных, выявления доминирующих компонент и обнаружения линейных зависимостей.

## 2 Пример 1: Матрица $4 \times 3$ с целыми значениями

Рассмотрим матрицу

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \\ 1 & 2 & 3 \end{bmatrix}.$$

### 2.1 Результаты SVD-разложения

После применения SVD получены следующие компоненты:

### 2.1.1 Левые сингулярные векторы ( $U$ )

$$U = \begin{bmatrix} -23.9467 & -39.4166 & 12.8802 \\ 4.95818 & 7.91318 & -1.92026 \\ 20.3764 & 33.0851 & -9.59154 \\ 8.47097 & 13.8436 & -4.25607 \end{bmatrix}.$$

### 2.1.2 Сингулярные значения ( $\Sigma$ )

$$\Sigma = \begin{bmatrix} 17.2337 & 0 & 0 \\ 0 & 1.41421 & 0 \\ 0 & 0 & 6.92779 \times 10^{-14} \end{bmatrix}.$$

### 2.1.3 Правые сингулярные векторы ( $V^T$ )

$$V^T = \begin{bmatrix} -1.47052 & -1.64275 & -1.08067 \\ 0.32124 & -0.222946 & -0.255682 \\ 1.282 & 0.365862 & 0.127841 \end{bmatrix}.$$

## 2.2 Восстановленная матрица

Перемножив компоненты, получаем:

$$A_{\text{SVD}} = U \Sigma V^T = \begin{bmatrix} 0.999999 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \\ 1 & 2 & 3 \end{bmatrix}.$$

Отметим, что небольшие отклонения (например, 0.999999 вместо 1) вызваны округлением.

## 3 Пример 2: Матрица $6 \times 4$ с вещественными значениями

Исходная матрица:

$$A = \begin{bmatrix} 1.01 & 2.03 & 3.02 & 4.01 \\ 5.01 & 6.98 & 7.01 & 8.03 \\ 9.04 & 10.00 & 11.01 & 12.02 \\ 13.03 & 14.01 & 15.03 & 16.04 \\ 17.02 & 18.01 & 19.04 & 20.01 \\ 21.01 & 22.03 & 23.00 & 24.02 \end{bmatrix}.$$

### 3.1 Результаты SVD-разложения

#### 3.1.1 Левые сингулярные векторы ( $U$ )

$$U = \begin{bmatrix} -57.1875 & -147.339 & -83.883 & 84.7888 \\ 24.6923 & 65.9048 & 37.5444 & -38.0524 \\ 11.1378 & 27.9343 & 15.4523 & -15.2472 \\ -28.9988 & -77.943 & -43.9788 & 45.5893 \\ 75.962 & 194.281 & 111.745 & -110.356 \\ 16.5782 & 38.1967 & 22.5392 & -20.6653 \end{bmatrix}.$$

#### 3.1.2 Сингулярные значения ( $\Sigma$ )

$$\Sigma = \begin{bmatrix} 70.1229 & 0 & 0 & 0 \\ 0 & 2.52816 & 0 & 0 \\ 0 & 0 & 0.705487 & 0 \\ 0 & 0 & 0 & 0.0297956 \end{bmatrix}.$$

#### 3.1.3 Правые сингулярные векторы ( $V^\top$ )

$$V^\top = \begin{bmatrix} 0.609307 & -0.0281399 & -0.949436 & -0.266471 \\ 1.50337 & 1.32126 & 0.823925 & -0.0273518 \\ 0.876698 & 0.25346 & 0.608129 & 0.811794 \\ -0.835883 & -1.46239 & -0.538473 & -0.520886 \end{bmatrix}.$$

### 3.2 Восстановленная матрица

$$A_{\text{SVD}} = U \Sigma V^\top = \begin{bmatrix} 1.01 & 2.03 & 3.02 & 4.01 \\ 5.01 & 6.98 & 7.01 & 8.02999 \\ 9.04 & 9.99999 & 11.01 & 12.02 \\ 13.03 & 14.01 & 15.03 & 16.04 \\ 17.02 & 18.01 & 19.04 & 20.01 \\ 21.01 & 22.03 & 23 & 24.02 \end{bmatrix}.$$

## 4 Пример 3: Матрица с преобладанием нулей

Исходная матрица:

$$A = \begin{bmatrix} 0 & 0 & 3 \\ 0 & 7 & 0 \\ 0 & 0 & 0 \\ 0 & 5 & 6 \\ 9 & 0 & 0 \end{bmatrix}.$$

## 4.1 Результаты SVD-разложения

### 4.1.1 Левые сингулярные векторы ( $U$ )

$$U = \begin{bmatrix} -7.79046 & 288.914 & 118.992 \\ -283.162 & 1310.02 & 511.065 \\ -48.8092 & 42.5853 & 8.67597 \\ 261.929 & 1094.96 & 517.751 \\ 2240.31 & -151.082 & 290.258 \end{bmatrix}.$$

### 4.1.2 Сингулярные значения ( $\Sigma$ )

$$\Sigma = \begin{bmatrix} 15.1881 & 0 & 0 \\ 0 & 1.31756 & 0 \\ 0 & 0 & 1.00000 \end{bmatrix}.$$

### 4.1.3 Правые сингулярные векторы ( $V^T$ )

$$V^T = \begin{bmatrix} -0.286197 & -13.2504 & -1.49082 \\ 2.33793 & -5.57673 & 0.24523 \\ 9.63434 & 0 & 0 \end{bmatrix}.$$

## 4.2 Восстановленная матрица

$$A_{\text{SVD}} = U \Sigma V^T = \begin{bmatrix} 0 & -2.38419 \times 10^{-7} & 3 \\ 0 & 7 & 2.38419 \times 10^{-7} \\ 0 & 0 & 0 \\ 0 & 5 & 6 \\ 9 & 0 & 0 \end{bmatrix}.$$

## 5 Пример 4: Матрица $4 \times 5$ с комплексными значениями

Рассмотрим матрицу, заданную следующими комплексными элементами:

$$A = \begin{bmatrix} 1.0 + 2.0i & 3.0 - 1.0i & -4.5 + 0.5i & 2.2 - 3.3i & 0.0 - 1.0i \\ 5.5 + 2.2i & 3.3 + 3.3i & -6.7 + 4.4i & 2.1 + 1.1i & -3.4 - 2.5i \\ 4.2 + 0.0i & 1.1 - 1.1i & 7.8 - 3.3i & -4.2 + 4.1i & 0.0 + 0.0i \\ 5.3 - 2.2i & -6.5 + 1.3i & 8.1 - 6.7i & 2.3 - 3.4i & -4.6 + 0.7i \end{bmatrix}.$$

Вычисление SVD-компонентов опустим, так как тест не помещается на странице, и сразу перейдем к восстановленной матрице.

## 5.1 Восстановленная матрица

Перемножив компоненты, получаем:

$$A_{\text{SVD}} = \begin{bmatrix} (1, 2) & (3, -0.999999) & (-4.5, 0.499999) & (2.2, -3.3) \\ (5.5, 2.2) & (3.3, 3.3) & (-6.7, 4.4) & (0, 0) \\ (-3.4, -2.5) & (4.2, -2.83122e-07) & (1.1, -1.1) & (0, 0) \\ (-4.2, 4.1) & (-1.66893e-06, -4.76837e-07) & (5.3, -2.2) & (0, 0) \\ (8.1, -6.7) & (2.3, -3.4) & (-4.6, 0.700001) & (0, 0) \end{bmatrix}.$$

Результат восстановления совпадает с входной матрицей (при незначительных погрешностях вычислений).

Стоит отметить, что вычисления над комплексными матрицами необходимо выполнять с помощью `Eigen::JacobiSVD`, тогда как для вещественных матриц использовалось `Eigen::BDCSVD`.

## 6 Тесты на больших матрицах

Теперь проведем тесты на больших матрицах. В качестве метрики будем использовать норму Фробениуса разности матриц. Относительная ошибка вычисляется по формуле:

$$\text{Relative Error} = \frac{\|A - A_{\text{SVD}}\|_F}{\|A\|_F},$$

где  $\|X\|_F = \sqrt{\sum_{i,j} |X_{ij}|^2}$  — норма Фробениуса матрицы  $X$ . Данная ошибка демонстрирует, насколько точно алгоритм восстанавливает исходную матрицу. Будем сравнивать эту ошибку с результатом, полученным с использованием алгоритма `Eigen::SVD`.

### 6.1 Для матрицы размером $25 \times 24$

Ошибка на собственном алгоритме —  $1.19338 \times 10^{-7}$ ;

Ошибка на алгоритме `Eigen::svd` —  $1.61071 \times 10^{-6}$ .

### 6.2 Для матрицы размером $52 \times 51$

Ошибка на собственном алгоритме —  $1.67005 \times 10^{-7}$ ;

Ошибка на алгоритме `Eigen::svd` —  $2.11554 \times 10^{-6}$ .

### 6.3 Для матрицы размером $95 \times 94$

Ошибка на собственном алгоритме –  $2.13266 \times 10^{-7}$ ;

Ошибка на алгоритме `Eigen::svd` –  $1.92261 \times 10^{-6}$ .

## 7 Заключение

В результате проведённого исследования можно сделать следующие выводы:

- Сингулярное разложение (SVD) является мощным инструментом для анализа структуры матриц. Оно позволяет разложить любую матрицу  $A \in \mathbb{R}^{m \times n}$  на произведение трёх матриц  $U$ ,  $\Sigma$  и  $V^T$ , что даёт возможность выявлять доминирующие компоненты и оценивать линейные зависимости в данных.
- Примеры, приведённые в данном документе, демонстрируют, что как для небольших матриц (например,  $4 \times 3$  и  $6 \times 4$ ), так и для матриц с преобладанием нулей, восстановленная матрица  $A_{\text{SVD}}$  очень точно приближается к исходной, что подтверждается незначительными отклонениями, обусловленными округлением.
- Тестирование на больших матрицах ( $25 \times 24$ ,  $52 \times 51$ ,  $95 \times 94$ ) с использованием нормы Фробениуса в качестве метрики позволяет количественно оценить относительную ошибку восстановления:

$$\text{Relative Error} = \frac{\|A - A_{\text{SVD}}\|_F}{\|A\|_F}.$$

По полученным результатам собственный алгоритм демонстрирует значительно меньшую ошибку по сравнению с `Eigen::SVD`, что свидетельствует о его высокой точности и стабильности.

- Для комплексных матриц восстановление производится также с высокой точностью, что подтверждается сравнением исходных и восстановленных матриц. При этом для комплексных данных рекомендуется использовать `Eigen::JacobiSVD` вместо `Eigen::BDCSVD`.

Таким образом, проведённое исследование демонстрирует, что реализованный собственный алгоритм SVD-разложения обладает высокой точностью восстановительных свойств и может быть эффективно применён в задачах обработки и анализа данных.